DAKER 경도 회귀 — 균형 샘플링 / D4 증강 실험 보고 (2026-10-17)

작성 2026-10-17 22:20 (Asia/Shanghai, UTC+8) · 마감 2026-10-19 10:00 KST = 09:00 (Asia/Shanghai) · 이 보고를 위해 새로 학습한 모델은 없음, 제출도 하지 않음
출처: `/workspace/daker/runs/bal_d4/` (report.md, analysis.md, results.json) · `/workspace/daker/final_clean/` (results.md, results.json) · 6절 블렌드 수치는 Mac Studio `~/AI/daker/final_clean/`, `~/AI/daker/cnn/runs/bal_d4/`의 OOF/test 배열을 읽기 전용으로 복사해 직접 계산 (`_report_1017/compute.py` → `computed.json`)

1. 요약

질문	답 (숫자는 모두 파일 값)
A(학습 방식 부족) vs B(원본 500장 다양성 부족)	**A를 뒷받침하는 증거는 약해요.** 균형 샘플링으로 D9 노출을 약 2배(1200 → 2445~2463 visit)로 늘려도 D9 편향은 줄지 않았어요(base −17.4 → bal_none −19.5 / bal_d4b −17.2). held-out 임베딩 kNN R^2도 어느 arm에서나 0.34~0.38에 머물러요. 결과는 B와 모순되지 않지만 B를 증명하지도 않아요.
가장 좋은 arm	**uni_none(증강 없음)**: 3-seed 평균모델 OOF **12.577**(base 12.937). 학습 seed별 값도 12.652~12.675로 흔들림이 가장 작아요. 학습 seed 42만 쓴 다른 fold seed 3개에서도 단독으로 orig_s42를 이겼어요 (12.952/12.828/12.894 vs 13.203/13.085/13.239).
블렌드(eq3)에서의 이득	fold seed 42(3 seed): 12.564 → **12.500**. fold seed 4개(42는 3 seed, 7/123/2026은 학습 seed 42 1개) 기준 eq3 평균은 12.686 → **12.642**(Δ −0.044)이고, fold seed 123에서는 **+0.012로 나빠졌어요**. 고경도 편향은 더 깊어져요(블렌드 hi −27.06 → −27.78, 4 fold seed 평균).
규정준수 재구축	final_clean 4-seed eq3 **12.686**(옛 12.667, 옛 값에는 BL1 라벨 선택 낙관 편향 포함). test 정규화 누수와 BL1 poly top-14 라벨 선택 누수를 고쳤어요. test 예측은 옛 11.33 후보와 corr 0.99869예요.
권장	**uni_none 버전 후보는 마감 전에 만드세요.** 학습 없이도 만들 수 있어요. fold seed 42의 uni_none test 예측 3개가 이미 있고, 규정준수 코드로 만들어졌어요. 다만 **최종 1순위로 정하는 것은 조건부**예요. 추가 OOF 6개(약 2시간)에서 이득이 확인될 때만 1순위로 올리세요(6.5절).

2. 규정준수 재구축 요약 (final_clean)

final_clean은 BL1 + ViT orig(3 seed) + ViT trans(3 seed)로 이루어진 파이프라인을 규정에 맞게 다시 만든 것이에요. test 이미지는 추론에만 쓰고, 합성 이미지와 Phase 2·3 가중치는 쓰지 않아요. 고친 누수 항목은 아래와 같아요.

#	위치	옛 동작	새 동작
1	ViT 채널 정규화	train과 test를 **각자 자기 집합의 mean/std**로 정규화 → test 통계 사용	fold-train으로 적합한 값을 val/test에 그대로 적용 (fold*_norm.json)
2·3	ViT trans p1/p99 창, 라벨 mu/sd	val fold를 포함한 train 500장 전체로 계산	fold-train으로만 계산
5	BL1 poly2 top-14 선택	전체 train 라벨과의 상관으로 열을 고른 뒤 CV → OOF 낙관 편향	각 학습 집합 안에서 `PolyTop` 적합
4·9	seed, hand/tex 특징	seed 미고정, 특징 생성 코드 없음	seed 고정(42/1/2), 같은 의미의 이미지별 특징으로 재구현(근사)

fold seed	BL1	orig(3seed)	trans(3seed)	eq3 균등	NNLS nCV	옛 eq3
42	12.944	12.937	12.971	12.564	12.631	12.539
7	13.279	13.145	13.146	12.842	12.939	12.795
123	12.874	12.856	12.999	12.523	12.582	12.538
2026	13.163	13.104	13.268	12.814	12.867	12.796
평균				**12.686**	**12.755**	12.667

- fold seed 42 NNLS 가중치 BL1/orig/trans = 0.4485/0.3176/0.2345 (in-sample 12.546). 최종 CSV `submission_final_clean.csv` (NNLS)와 `submission_final_clean_eq3.csv`가 있어요.

- test 예측은 옛 11.33 후보와 corr 0.99869, 평균 차 +0.12, RMS 차 0.61, max|diff| 3.78이에요. 재구축으로 생긴 0.019 악화(12.667 → 12.686)는 옛 BL1의 낙관 편향이 빠진 몫으로 봐요.
- 남은 미해결 항목: 외부 사전학습 가중치(DINOv2)를 대회 규정이 허용하는지 아직 확인하지 못했어요(10-15 보고 이월).

3. 실험 설계와 Step 1 감사

공통 설정: final_clean ViT-B orig(timm DINOv2), fold-train 정규화, KFold(5, rs=42), 학습 seed 42/1/2, 30 epoch, 추론 시 D4×8 TTA. 모든 arm의 loss 가중치는 1이에요.

arm	샘플링	학습 증강	비고
base (uni_d4b)	균등(permutation)	랜덤 D4 + 밝기 ±0.1	final_clean ViT orig 그대로 재사용
uni_none	균등	없음	신규
uni_d4	균등	D4만(무손실)	신규
bal_none	균형	없음	신규
bal_d4b	균형	D4 + 밝기 ±0.1	신규

균형 샘플링은 fold-train 라벨을 등간격 10 bin으로 나누고, 확률 ∝ 1/√(bin 빈도)로 복원추출해요. 분위수 bin은 정의상 빈도가 같아서 1/√freq를 적용해도 균등 추출과 똑같아져요. 그래서 등간격 bin을 썼어요.

Step 1 감사: 기존 실험 재사용

계획	기존 기록	판정
uniform + D4	final_clean ViT orig가 이미 D4+밝기 증강과 D4 TTA로 학습돼 있음	기준선으로 재사용
TTA 확장	cyc2 TTA24 이득 없음(+0.008)	재실행 안 함
mild 회전 ±12° + crop	aug_mild: 단독 13.6~13.9, nCV +0.05 악화	재실행 안 함
고경도 가중 loss	cyc2 hiw1: hi 편향 −24.9 → −23.2로 줄었지만 단독 RMSE +0.27 악화	재실행 안 함
VICReg(train-only)	ssl_train: seed 42 세 변형 모두 기준 미달	재실행 안 함
증강 없음 / 균형 샘플링	기록 없음	신규 실행

학습 노출량 (fold당 30 epoch 합계, 10분위별 sample-visit)

설정	D0	D1	D2	D3	D4	D5	D6	D7	D8	D9
uniform (기준)	1200	1200	1200	1200	1200	1200	1200	1200	1200	1200
bal_d4b (실측 15 fold-run)	1736	1076	958	889	865	879	917	957	1280	2445
bal_none (실측 15 fold-run)	1732	1075	966	884	860	873	914	958	1276	2463

기존 학습은 이미 모든 분위를 균등하게(fold당 약 1200 visit) 노출했어요. 그러니 "양 끝 분위가 덜 학습됐다"는 설명은 처음부터 성립하지 않았어요. 균형 arm도 고유 원본은 400/400장을 모두 썼어요.

4. 결과 (fold seed 42)

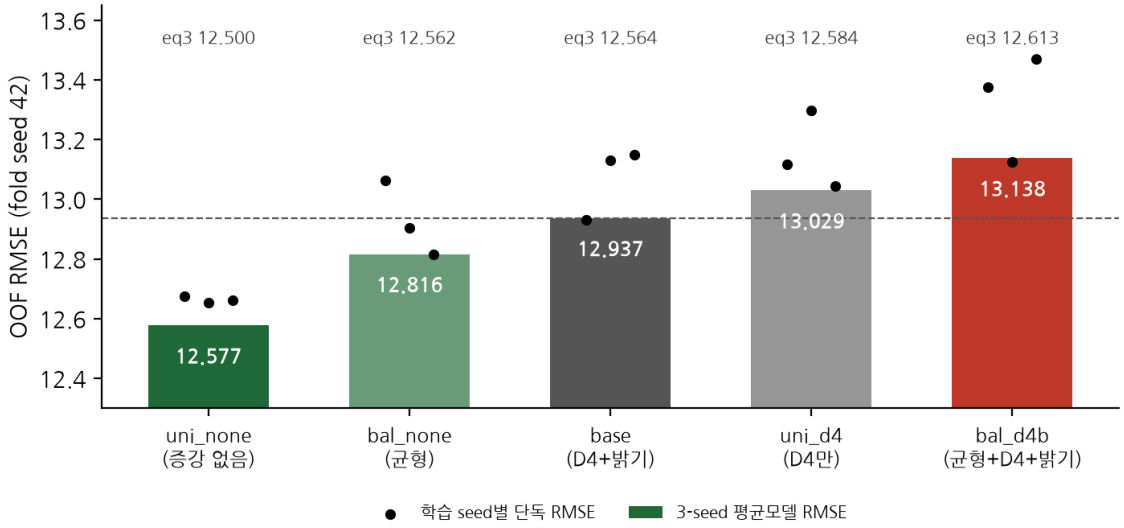


그림 1. arm별 단독 OOF RMSE(막대는 3-seed 평균모델, 점은 학습 seed별 값). 점선은 base, 위쪽 숫자는 orig를 해당 arm으로 바꾼 eq3예요.

arm	seed별 RMSE (s1 / s2 / s42)	평균모델	hi bias	lo bias	AUPRC	P@18	eq3(교체)	eq4(추가)
uni_none	12.675 / 12.652 / 12.661	**12.577**	−28.0	+16.8	0.360	0.333	**12.500**	12.510
bal_none	13.062 / 12.905 / 12.814	12.816	−28.0	+17.1	0.352	0.444	12.562	12.558
base (uni_d4b)	12.932 / 13.129 / 13.149	12.937	−25.8	+17.2	0.297	0.278	12.564	12.602
uni_d4	13.117 / 13.297 / 13.043	13.029	−25.5	+17.3	0.313	0.278	12.584	12.614
bal_d4b	13.375 / 13.125 / 13.471	13.138	−24.6	+17.1	0.340	0.333	12.613	12.630

hi = 실제 >230 표본의 평균 (예측−실제), lo = <170 표본의 평균. AUPRC와 P@18은 >230 판별 지표예요. eq3 기준선(BL1 + orig3 + trans3 균등) = 12.564.

경도 10분위별 bias (예측 − 실제, seed 평균모델)

arm	D0	D1	D2	D3	D4	D5	D6	D7	D8	D9	D0 RMSE	D9 RMSE
base	+15.6	+7.8	+4.2	+2.0	+0.1	+1.6	−2.1	−3.2	−8.6	−17.4	19.2	21.2
uni_none	+15.4	+8.3	+4.7	+2.4	−0.2	+1.2	−2.0	−4.1	−9.7	−19.7	18.1	22.3
bal_none	+15.6	+8.3	+5.2	+2.7	+0.1	+0.8	−1.9	−4.0	−10.2	−19.5	18.3	22.4
uni_d4	+15.8	+7.7	+4.0	+1.5	+0.1	+1.8	−2.4	−3.5	−8.8	−17.6	19.4	21.5
bal_d4b	+15.3	+7.6	+4.3	+2.1	+0.5	+1.7	−1.9	−3.1	−8.9	−17.2	18.9	21.1

분위 경계(HV): 152.0, 172.2, 179.3, 184.4, 188.7, 192.5, 198.1, 201.6, 207.3, 217.1, 264.1. uni_none의 이득은 가운데 분위(D3~D7 RMSE 8.4/7.1/9.9/9.4/8.8 vs base 9.2/8.3/11.1/10.0/9.6)와 D0에서 나와요. D9에서는 오히려 나빠져요(22.3 vs 21.2). 양 끝으로 갈수록 평균 쪽으로 끌려가는 수축이 증강을 없애도 그대로이거나 조금 더 강해졌어요.

독립 fold seed 확장 (학습 seed 42 1개)

fold seed	final_clean orig_s42	uni_none_s42	Δ	bal_none_s42	Δ
7	13.203	12.952	**−0.251**	12.948	−0.255
123	13.085	12.828	**−0.257**	13.209	**+0.124**
2026	13.239	12.894	**−0.345**	13.008	−0.231

fold seed 42의 같은 seed 비교(s42)는 12.661 vs 13.149(−0.488)이에요. 단독 모델 기준으로 uni_none은 fold seed 4개 모두에서 base를 이겼고, bal_none은 3/4에서 이겼어요.

5. 임베딩 분석과 A/B 해석

임베딩 (held-out 100장, 5 fold 평균)	kNN R²	probe PCA5 R²	PCA20 R²	Spearman	D4 cos	D4 일관성 r	고경도18 sil. k=2/3
pretrained DINOv2 (미학습)	0.030	0.038	0.112	0.026	0.9466	0.924	0.150/0.173
base s42	0.368	0.437	0.387	0.265	0.9361	0.955	0.129/0.105
uni_none s42	0.351	0.408	0.379	0.265	0.9255	0.917	0.137/0.113
uni_d4 s42	0.383	0.448	0.390	0.283	0.9390	0.953	0.114/0.116
bal_none s42	0.348	0.410	0.385	0.226	0.9055	0.915	0.079/0.087
bal_d4b s42	0.340	0.419	0.369	0.234	0.9282	0.956	0.089/0.090

Spearman = 임베딩 거리와 |ΔHVI|의 순위상관. D4 일관성 r은 불변성 지표일 뿐 예측력이 아니에요. 고경도 18장 silhouette는 fold별로 표준화한 뒤 합친 근사값이고, 값이 0.08~0.17이라 뚜렷한 하위 군집은 없어요(과해석 금지).

- **A 쪽 증거가 약한 이유:** 노출 분포를 바꿔도(균형) RMSE가 나아지지 않았어요(bal_d4b 13.138 vs base 12.937, bal_none 12.816 vs uni_none 12.577). 미세조정 후 임베딩 분리도(kNN R² 0.340~0.383)도 arm 간 차이가 작고 RMSE 순위와 맞지 않아요. 예를 들어 uni_d4는 R²가 가장 높지만 RMSE는 4위예요.
- **B와 모순되지 않는 이유:** 고경도 끝(D9) 편향은 노출을 2배로 늘려도 −17~−20에 머물러요. report.md가 인용한 학습곡선(80 → 400장에서 단조 감소)도 데이터를 더 모으면 개선될 여지와 맞아떨어져요. 다만 라벨 잡음이나 이미지가 담지 못하는 정보일 가능성도 이 실험으로는 구분할 수 없어요.
- **uni_none이 좋은 이유는 아직 해석하지 않았어요.** 증강을 없앤 모델은 D4 불변성이 낮아졌어요(cos 0.9255 vs 0.9361). 방향이나 밝기 단서가 유용했을 가능성이 있지만 검증하지 않았어요. 학습할 때는 D4를 쓰지 않았는데 추론할 때는 D4×8 TTA를 쓰는 불일치도 그대로 있고, 이 조합은 시험하지 않았어요.

6. 가능성: uni_none이 규정준수 최종 후보로 유망한가

6.1 OOF 배열로 직접 계산한 eq3 블렌드 (orig 자리를 uni_none으로 교체)

eq3 = (BL1 + ViT orig + ViT trans)/3에서 orig 자리만 uni_none으로 바꿨어요. BL1과 trans(3 seed)는 해당 fold seed의 final_clean 배열을 그대로 써요. 재계산한 final_clean eq3는 results.json과 일치해요(fs42 12.5643).

fold seed	uni_none 학습 seed	final_clean eq3 (orig 3 seed)	eq3 orig s42만 (동일조건 1 seed)	eq3 uni_none	Δ vs final_clean	Δ vs orig s42	NNLS nCV fc → uni	블렌드 hi bias fc → uni
42	**3개** (42/1/2)	12.564	—	**12.500**	−0.065	—	12.631 → 12.563	−27.07 → −27.81
42	1개 (42)	12.564	12.589	12.499	−0.066	−0.091	12.631 → 12.570	−27.07 → −27.63
7	1개 (42)	12.842	12.824	12.784	−0.058	−0.040	12.939 → 12.873	−26.85 → −27.55
123	1개 (42)	12.523	12.577	12.535	**+0.012**	−0.041	12.582 → 12.614	−27.26 → −28.25
2026	1개 (42)	12.814	12.823	12.750	−0.064	−0.073	12.867 → 12.817	−27.04 → −27.69
4 fold seed 평균	fs42는 1 seed 행	**12.686**	12.703	**12.642**	**−0.044**	−0.061	12.755 → 12.719	−27.06 → −27.78

fs42를 3-seed 행(12.500)으로 바꿔도 4-seed 평균은 12.642로 같아요. fs42에서 orig 3 seed 평균에 uni_none 3 seed를 더하면(eq4) 12.510, orig와 uni_none을 반반 섞으면 12.518이에요. 교체(12.500)가 가장 좋아요. uni_none과 orig 3 seed OOF의 상관은 fold seed별로 0.946~0.955예요.

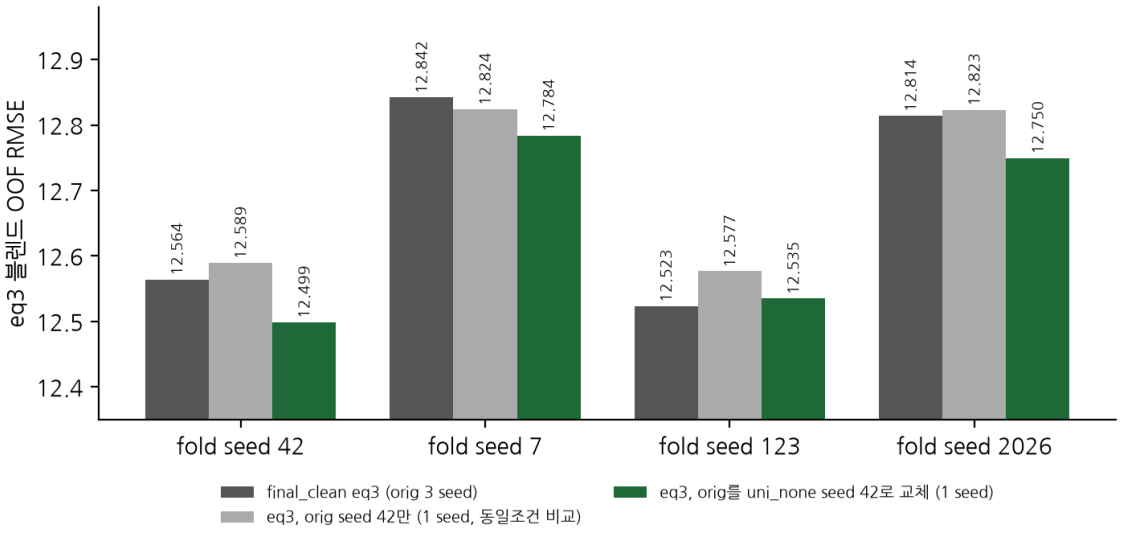


그림 2. fold seed별 eq3. final_clean(orig 3 seed), 같은 조건의 orig seed 42 1개, uni_none seed 42 1개를 비교했어요. 1 seed끼리 비교하면 uni_none이 4/4에서 이기고, 3-seed final_clean과 비교하면 3/4에서 이겨요.

6.2 test 예측 수준 비교 (배열 기반, CSV는 만들지 않음)

vit_arm.py는 fold-train으로 정규화하고 5 fold 평균에 D4 TTA를 적용해 test.npy를 저장해요. 그래서 **fold seed 42의 uni_none test 예측(seed 42/1/2)이 이미 있어요.** final_clean의 test 예측도 fold seed 42 모델로만 만들어요. 배열에서 재구성한 final_clean eq3는 `submission_final_clean_eq3.csv`와 정확히 일치해요(max|diff| 0.0). 여기에 uni_none을 넣은 eq3 예측은 final_clean eq3와 corr **0.9973**, 평균 차 −0.12, RMS 차 0.91, max|diff| 3.73이에요. uni_none test 예측의 표준편차는 11.09로 orig의 12.10보다 작아요. 수축이 더 강하다는 OOF 결과와 같은 방향이에요.

6.3 주의 사항

- **seed 수가 적어요:** fold seed 7/123/2026의 uni_none은 학습 seed 42 하나뿐이에요. final_clean은 3 seed 평균이라 비교가 uni_none에 불리한 쪽이에요. 그래도 증거가 얇다는 점은 바뀌지 않아요.
- **잡음 규모:** 같은 seed로 다시 돌려도 단독 RMSE가 약 0.1 달라질 수 있어요. 블렌드 이득 0.04~0.06은 이 잡음보다 작고, fold seed 123에서는 부호가 반대(+0.012)예요. 단독 이득(−0.25~−0.49)은 잡음보다 확실히 크지만, BL1과 trans가 섞이면서 대부분 희석돼요.
- **고경도 편향이 깊어져요:** 단독 hi −28.0 vs −25.8, 블렌드 hi는 fold seed 4개 모두에서 0.6~1.0 더 음수예요. 반면 AUPRC(0.360 vs 0.297)와 P@18(0.333 vs 0.278)은 좋아져요. 순위는 더 잘 맞히지만 높은 쪽을 덜 올려 잡는다는 뜻이에요.
- **재현성 자료가 부족해요:** uni_none은 `--nockpt`로 학습해서 fold 체크포인트와 sha256이 없어요. final_clean fs42는 체크포인트가 있어요. 코드 검증에서 가중치를 요구하면 다시 학습해야 하고, 다시 학습하면 예측이 약 0.1 수준으로 달라질 수 있어요.
- **uni_none CSV는 아직 없어요.** 다만 만드는 데 학습이 필요하지는 않아요(6.2). 요청 문구에 있던 "4 fold seed × 3 학습 seed 학습 + test 추론"은 **검증용** 작업이에요. 12개 중 6개는 이미 끝났어요.

6.4 소요 시간 (bal_d4 / final_clean progress.txt 실측)

실행 조건	모델 1개 (5 fold × 30 ep)	근거
MPS 단독 1 chain	약 20분 (fold당 239~240 s)	uni_none_s2 17:59→18:19, arms_fs 6개 각 20분 (10-16)
2 chain 병렬 (final_clean main)	chain당 약 37~38분	orig/trans_s42 → s1 → s2: 08:31 → 09:08 → 09:46
다른 작업과 GPU 공유	약 50~60분	bal_d4 seed 42/1 단계, final_clean extra 단계

작업	모델 수	예상 (단독 / 공유)	필요성
(a) uni_none eq3 / NNLS CSV 생성 (기존 test.npy 3개 사용)	0	수 분	후보 확보
(b) fold seed 7/123/2026 × 학습 seed 1/2 OOF	6	약 2.0시간 / 약 4~6시간	1순위 판정용 3-seed 근거
(c) fold seed 42 × seed 42/1/2 재학습 (체크포인트 저장)	3	약 1.0시간 / 약 2~3시간	가중치 제출·재현이 필요할 때

지금(10-17 22:20)부터 마감(10-19 09:00, Asia/Shanghai)까지 약 34.7시간 남았어요. (b)+(c) 9개 모델을 GPU 단독으로 돌리면 약 3시간이라 여유가 커요.

6.5 판단과 권장

> **판단:** uni_none은 **유망하지만 기대 이득이 작은** 규정준수 후보예요. 이번 연구에서 바꾼 것 가운데 단독 RMSE를 fold seed 4개 모두에서 크게(−0.25~−0.49) 낮춘 것은 이것뿐이에요. 하지만 블렌드에 넣으면 이득이 평균 −0.044(fold seed 4개, 대부분 1 seed)로 줄어요. 이는 같은 seed 재실행 잡음보다 작고, 고경도 편향이라는 대가도 있어요. test 예측은 현재 후보와 corr 0.997이라 위험은 작지만, 기대할 수 있는 이득도 작아요.
>
> **권장: 마감 전에 uni_none 기반 후보를 만드세요.**
>
> - 지금 바로: (a) 기존 배열로 `eq3_uni` 와 NNLS 버전 CSV를 만들고 ID·열 순서 assert를 통과시켜요(학습 없음). (b) 6개 모델을 GPU 단독으로 걸어 두세요(약 2시간, 다른 작업과 GPU를 같이 쓰지 않기). 가중치 제출이 필요하면 (c)도 함께 돌리세요(+1시간).
> - **1순위 승격 조건 (미리 고정):** 3-seed uni_none eq3가 fold seed 4개 중 3개 이상에서 final_clean eq3보다 낮고, 평균 Δ가 −0.03 이하일 때만 uni_none 버전을 1순위로 해요. 조건을 못 채우면 **final_clean(NNLS)을 1순위로 유지**하고, 최종 선택을 2개 할 수 있다면 uni_none 버전을 2순위로 둬요.
> - 판정은 10-18 저녁(Asia/Shanghai)까지 끝내세요. 학습을 마감 직전까지 미루지 마세요.

7. 부록: 파일과 재현

- 보고 소스: `/workspace/daker/runs/_report_1017/` (report.html, charts.py, compute.py, computed.json, fig1_arms.png, fig2_eq3_fs.png, data/ = Mac Studio에서 읽기 전용으로 복사한 OOF/test 배열, train.csv, 소스 코드).
- 6.1의 hi/lo 정의는 common.py와 같아요(hi: y>230, lo: y<170). nCV = NNLS(절편 포함) 5-fold × 20회(rs 100~119)로, final_clean blend.py와 같은 방법이에요.
- 모든 수치는 위 파일에서 읽거나 그 배열로 계산했어요. 이 보고를 위해 학습, 제출, Mac Studio 원본 파일 수정은 하지 않았어요.